



PRML Chapter.1

Introduction

2017010698
수학과 오서영

- 0. Prolog
- 1. Example : Polynomial Curve Fitting
- 2. Probability Theory**
- 3. Model Selection**
- 4. The Curse of Dimensionality
- 5. The Decision Theory
- 6. Information Theory

2. Probability Theory

패턴인식 -> 불확실성(uncertainty) 의 문제

: finite size of data sets, Noise on measurements

- **Probability Theory**

: consistent framework

for the quantification and manipulation of uncertainty

- **Decision Theory**

: incomplete or ambiguous information -> optimal predictions

2. Probability Theory

Probability Theory – Frequentist

: 실제 데이터가 존재해야 불확실성을 정량화 가능
-> 빈도를 통해 모델링

Probability Theory - Bayesian probabilities

: 사건이 발생하지 않은 경우에도 확률을 부여할 수 있다
-> 좀 더 불확실한 경우에도 모델링이 가능

Curve Fitting 문제에서는 모수 w 가 알려지지 않은
고정된 값으로 여겨졌다. (unknown but fixed)
하지만 베이지안 방식은 모든 값이 확률 값이므로
이를 하나의 확률 변수로 고려

2. Probability Theory

Probability Theory - Bayesian probabilities

$$p(\mathbf{w}|D) = \frac{p(D|\mathbf{w})p(\mathbf{w})}{p(D)}$$

- 관찰되는 데이터가 존재하기 이전에 이미 $p(\mathbf{w})$ 를 통해 \mathbf{w} 의 불확실한 정도를 수식에 반영
-> prior probability distribution **$p(\mathbf{w})$**
- how probable the observed data set is for different settings of the \mathbf{w}
-> likelihood **$p(D|\mathbf{w})$**

$$\text{posterior} \propto \text{likelihood} \times \text{prior}$$

$$\text{normalization } p(D) = \int p(D|\mathbf{w})p(\mathbf{w})d\mathbf{w}$$

2. Probability Theory

가우시안 분포 (Gaussian distribution) = 정규분포


$$N(x | \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$$

Parameter :

μ : mean

σ : standard deviation

정확도(precision) := $1/\sigma^2$



$$N(x | \mu, \sigma^2) > 0 \quad (1.47)$$

$$\int_{-\infty}^{\infty} N(x | \mu, \sigma^2) dx = 1 \quad (1.48)$$

$$E[x] = \int_{-\infty}^{\infty} N(x | \mu, \sigma^2) \cdot x dx = \mu \quad (1.49)$$

$$E[x^2] = \int_{-\infty}^{\infty} N(x | \mu, \sigma^2) \cdot x^2 dx = \mu^2 + \sigma^2 \quad (1.50)$$


$$\text{var}[x] = E[x^2] - E[x]^2 = \sigma^2 \quad (1.51)$$

2. Probability Theory

(EX) 관찰 데이터 집합 $\mathbf{x}=(x_1,\dots,x_N).T$
-> 이 데이터 집합 하나가 관찰될 수 있는 확률?

각각의 데이터가 발현되는 가능성 : i.i.d

$$p(\mathbf{x}|\mu, \sigma^2) = \prod_{n=1}^N N(x_n | \mu, \sigma^2)$$



2. Probability Theory

(EX) 관찰 데이터가 하나의 가우시안 분포를 따름.

얻는것 : 관찰 데이터 집합

문제 : 가우시안 분포를 결정

-> 주어진 샘플이 어떤 가우시안 분포에서 나왔는지 결정

-> $p(x | \mu, \sigma^2)$ 를 이용하여 이러한 관찰 결과를 만들어낼 만하다고 생각할 수 있는 가장 타당한 μ 와 σ 찾기

→ **Parameter estimation**

$$\ln p(\mathbf{x} | \mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 - \frac{N}{2} \ln \sigma^2 - \frac{N}{2} \ln(2\pi)$$

→ **maximize**

각각 샘플에 대한
평균, 분산

$$\mu_{ML} = \frac{1}{N} \sum_{n=1}^N x_n \quad (1.55)$$

$$\sigma_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{ML})^2 \quad (1.56)$$


→ *MLE (Maximum likelihood estimation)* -> 쉽게 overfit

3. Model Selection

데이터가 충분하다면 다양한 모델을 학습하여
가장 적당한 파라미터 값을 추정할 수 있다

cross validation

: Random 으로 고른 $(S-1)/S$ 를 Training Set 으로,
1/S 를 Test set 으로 학습 진행
-> 학습 데이터에만 종속적이고
Overfitting이 발생하지 않는 측정값을 찾는 것.



3. Model Selection

information criteria

: MLE 로 인해 발생하는 overfit을 막기 위해 페널티 조건을 추가

(EX) **AIC**(Akaike information criterion)

$$\ln p(D|\mathbf{w}_{ML}) - M$$

M : 모델에서 사용한 parameter 의 개수 (penalty)

현재 주어진 데이터를 가장 적합하게 만드는 parameter 를
추정하되 모델이 복잡해서는 안된다

즉, 동일한 성능을 내는 모델 두개가 제공된다면
여기서 덜 복잡한 모델을 선택할 수 있어야 한다.